

AI RECOVERY COPILOT

Ecosistema de Automatizacion IA Autonomo para Negocios

Documentacion tecnica, arquitectura, datos, costos, seguridad y validacion

PoC academica con datos sinteticos - escenario de referencia: BARBUSS RISK Argentina

Alcance: El sistema realiza screening secundario y priorizacion. No determina responsabilidad juridica, fraude ni inicio automatico de recuperio. La decision final permanece en manos de un analista humano.

Version documental: 13/09/2026

1. Resumen ejecutivo

AI Recovery Copilot es una prueba de concepto de un ecosistema de automatización orientado al preanálisis y priorización de posibles oportunidades de recupero en expedientes de seguros patrimoniales. El proyecto utiliza BARBUSS RISK Argentina como escenario de referencia y trabaja exclusivamente con datos sintéticos. No se asume que los procesos simulados ni las oportunidades detectadas representen su operación interna real. BARBUSS declara servicios de Specialty Insurance Management, Claims Management y Recoveries, lo que hace coherente el contexto de negocio modelado [1].

En Argentina, la Ley 17.418 establece en su artículo 80 la subrogación del asegurador, hasta el monto de la indemnización abonada, respecto de derechos del asegurado contra terceros por razón del siniestro, con exclusión de seguros de personas [2]. En esta PoC, esa referencia se utiliza solo como contexto general: el workflow no realiza una determinación jurídica de procedencia.

La solución integra n8n como orquestador, Airtable como base operativa y capa persistente, OpenAI GPT-5 Mini para interpretación semántica, Gmail para notificaciones y un formulario independiente para Human-in-the-Loop (HITL). El procesamiento masivo no queda bloqueado esperando una decisión humana: Airtable desacopla el flujo automático de la revisión posterior.

Componente	Tecnología	Rol
Orquestación	n8n	Triggers, reglas, scoring, APIs, rutas y control de errores
Base de datos	Airtable	Expedientes, revisiones humanas, logs y dashboard
IA	OpenAI GPT-5 Mini	Extracción semántica estructurada sobre texto no estructurado
Salida	Gmail	Notificación de casos priorizados
HITL	n8n Form + Airtable	Decisión humana en ejecución independiente
Procesamiento masivo	OpenAI Batch API	Ejecución diferida con descuento del 50% [5]

2. Arquitectura del ecosistema

La arquitectura se divide en cuatro bloques: A) ingesta y validación, B) análisis y priorización, C) salida y revisión humana, y D) resiliencia, observabilidad y optimización. El mapa siguiente resume triggers, routers, APIs, nodos de IA y destinos sin replicar el detalle de cada nodo del canvas de n8n.




Figura 1. Arquitectura funcional de AI Recovery Copilot.

Decision arquitectonica clave: El procesamiento automatico y el HITL se ejecutan de forma independiente. Airtable funciona como puente persistente, evitando que una ejecucion masiva quede suspendida mientras una persona revisa un caso.

2.1. Ingesta y validacion

Una ejecucion programada consulta Airtable en busca de expedientes pendientes. Antes de consumir IA, el flujo aplica reglas determinísticas sobre elegibilidad de ramo y disponibilidad de un relato mínimo. Los casos que no cumplen estas condiciones se derivan a estados especificos, reduciendo consumo innecesario y manteniendo trazabilidad.

```

AND(
  {Estado} = 'Pendiente',
  NOT({Derivado a recupero})
)
  
```

Los IDs de Airtable y valores del expediente viajan como variables dinamicas. La logica no contiene IDs de casos concretos hardcodedos.

2.2. Analisis semantico y priorizacion

Los expedientes aptos se transforman en un input estructurado. GPT-5 Mini se utiliza exclusivamente para interpretar informacion no estructurada: tercero mencionado, identificabilidad, senales de posible responsabilidad, contradicciones, ausencias explicitamente declaradas y posibles limitaciones contractuales. La salida se restringe mediante JSON Schema y Structured Outputs, funcionalidad soportada por el modelo [4].

IA semantica	Logica deterministica
Tercero mencionado	Impacto economico
Identificabilidad	Urgencia
Senales de responsabilidad	Evidence Score
Contradicciones	Recovery Score
Informacion faltante	Prioridad
Posible limitacion contractual	Estados y routing
Resumen semantico	HITL, persistencia y logs

El modelo no recibe instrucciones para calcular montos, fechas, scores ni ground truth del stress test. Las operaciones que deben ser reproducibles permanecen fuera del LLM.

2.3. Salida y Human-in-the-Loop

Luego de persistir el analisis, Gmail notifica el caso. La revision humana se inicia desde un formulario separado; cada envio crea una nueva ejecucion, busca el expediente que aun permanece en estado Pendiente revision humana, registra la decision y enruta el resultado.

Decision humana	Resultado operacional
Aprobar para recuperio	Estado Aprobado para recuperio + Derivado a recuperio = Si
Solicitar informacion	Estado Informacion insuficiente
No priorizar	Estado No priorizado

El diseno original utilizaba Gmail Send and Wait dentro de la misma ejecucion. Durante las pruebas multi-item surgieron dependencias de contexto y riesgo de bloqueo. Se reemplazo por el esquema desacoplado actual. La documentacion de n8n indica que Send and Wait resulta apropiado para aprobaciones simples y sugiere mecanismos de espera dedicados para procesos mas complejos [6].

2.4. Resiliencia, observabilidad y optimizacion

El flujo incluye rutas independientes para errores de IA y persistencia, reintentos del nodo de IA, registro de ejecuciones y un dashboard de seguimiento. En paralelo, una rama diferida prepara solicitudes JSONL y utiliza OpenAI Files API + Batch API para procesamiento masivo no urgente.

3. Estrategia de scoring

Dimension	Peso	Interpretacion
Potencial de recupero	30%	Presencia, identificabilidad y senales vinculadas al tercero
Impacto economico	30%	Magnitud economica del expediente
Urgencia	25%	Antigüedad operativa desde el pago
Evidencia	15%	Consistencia y completitud de la informacion disponible

Recovery Score = 0.30 x Potencial + 0.30 x Impacto + 0.25 x Urgencia + 0.15 x Evidencia

Interpretacion: Recovery Score es un indice heuristico de priorizacion entre 0 y 100. No es probabilidad de exito ni monto esperado de recupero. Los pesos y umbrales son supuestos sinteticos de la PoC y requieren calibracion con datos historicos y especialistas antes de un uso productivo.

Overrides principales:

- Sin tercero mencionado: No elegible por regla.
- Urgencia critica: escalamiento de prioridad.
- Posible limitacion contractual: alerta legal para revision especializada.

4. Modelo de datos y esquemas JSON

Airtable es la capa operativa de persistencia. La base AI Recovery Copilot utiliza tres tablas relacionadas: Expedientes, Revisiones Humanas y Logs Ejecuciones.




Figura 2. Modelo relacional simplificado.

Grupo	Campos principales
Inputs	ID Expediente; Ramo; Tipo de siniestro; Fecha siniestro; Fecha pago; Monto pagado; Moneda; Relato asegurado; Nota analista; Informe policial; Fragmento contractual
Resultados	Potencial Score; Impacto Score; Urgencia Score; Evidencia Score; Recovery Score; Mini informe
Control workflow	Estado; Procesado por IA; Fecha ultima ejecucion; Derivado a recupero
HITL	Decision; Comentario analista; Fecha revision
Observabilidad	Fecha; Etapa; Resultado; Error; Mensaje error

4.1. JSON de transferencia hacia IA

```
{
  "id_expediente": "EXP-001",
  "ramo": "Auto",
  "tipo_siniestro": "Colision",
  "relato_asegurado": "...",
  "nota_analista": "...",
  "informe_policial": "...",
  "fragmento_contractual": "..."
}
```

4.2. JSON de salida semantica

```
{
  "tercero_mencionado": true,
  "tercero_identificable": "si",
  "senales_responsabilidad": "altas",
  "contradicciones_detectadas": false,
  "detalle_contradicciones": [],
  "informacion_faltante": [],
  "limitacion_contractual": "no_detectada",
  "detalle_limitacion": "",
  "resumen_semantico": "..."
}
```

El schema exige los nueve campos, restringe enums, tipa arrays y utiliza `additionalProperties = false`. Esto reduce variaciones de formato y facilita el consumo automatico por los nodos posteriores.

5. Estrategia de IA y optimizacion de costos

La arquitectura reserva el LLM para tareas semanticas. Filtros, fechas, montos, scoring, routing, HITL y logging se resuelven sin inferencia generativa. Esto evita pagar tokens por tareas mecanicas y facilita la auditoria del resultado.

Proceso	Mecanismo/ modelo	Modalidad	Decision de diseno	Costo relativo
Validaciones, fechas, scoring, estados	n8n IF / Code / Airtable	Sin LLM	Tareas mecanicas y reproducibles	Nulo en tokens
Extraccion semantica	GPT-5 Mini	Sincrona	Modelo validado en el dataset sintetico y con Structured Outputs	Bajo
Lectura documental densa	Claude (alternativa)	No implementada	Alternativa de arquitectura para documentos extensos; cambiar proveedor exigiria revalidacion	Variable
Procesamiento masivo no urgente	GPT-5 Mini + Batch API	Diferida, hasta 24h	Delegar lotes y certificar ahorro del 50% [5]	50% menos que equivalente sincrono
Prompt repetido	Prompt Caching	Automatico cuando aplica	Prefijo estable y datos variables al final	No medido en esta PoC

GPT-5 Mini publica precios estandar de USD 0,25 por millon de tokens de entrada, USD 0,025 para entrada cacheada y USD 2,00 por millon de tokens de salida, y soporta Batch y Structured Outputs [4].

5.1. Validacion real de OpenAI Batch API

La rama Batch fue implementada y ejecutada end-to-end. El archivo JSONL incluyo el prompt validado, el schema estructurado y los datos dinamicos por expediente. OpenAI acepto el archivo, creo el lote, lo proceso y devolvio el archivo de resultados.

Metrica	Resultado
Requests	8
Completados	8
Fallidos	0
HTTP de resultados	8/8 con status 200
Input tokens	6.978

Metrica	Resultado
Output tokens	7.620
Reasoning tokens incluidos en output	5.696
Tokens totales	14.598
Cached tokens	0
Modelo reportado	gpt-5-mini-2025-08-07

Con el precio estandar anterior, ese perfil de tokens costaria aproximadamente USD 0,01698 en modalidad sincrona. La Batch API aplica un descuento del 50% y una ventana de hasta 24 horas [5], por lo que el equivalente diferido es aproximadamente USD 0,00849.

Escenario extrapolado	Costo estimado para 500 casos
Sincrono, mismo perfil promedio	USD 1,06
Batch, mismo perfil promedio	USD 0,53
Ahorro estimado	USD 0,53 (50%)

Importante: El 50% se atribuye a la modalidad Batch, no a que el flujo se ejecute una vez por dia. Batch reduce el precio del procesamiento diferido; no reduce la cantidad de tokens.

5.2. Prompt Caching

La solicitud se estructuro con contenido estable al inicio (system prompt y schema) y datos variables del expediente al final, una practica recomendada para aumentar la reutilizacion de prefijos cuando el caching es elegible [7]. Sin embargo, la ejecucion real reporto `cached_tokens = 0`. Por lo tanto, este documento no atribuye ahorro efectivo a Prompt Caching.

Batch y Prompt Caching son mecanismos distintos y sus porcentajes de ahorro no deben sumarse de forma lineal. El caching queda como optimizacion potencial a medir en ejecuciones futuras.

6. Seguridad y resiliencia

Control	Implementacion en la PoC
Minimizacion de datos	El LLM recibe solo campos semanticos necesarios; montos, fechas, scores y ground truth quedan fuera
Credenciales	API keys gestionadas mediante credenciales de n8n; no se incluyen en prompts ni codigo visible
Reintentos IA	Retry On Fail con hasta 2 intentos
Error IA	Ruta ERR-01 registra el fallo

Control	Implementacion en la PoC
Error persistencia	Ruta ERR-02 registra fallos de guardado
Tipos y estructura	JSON Schema, enums y additionalProperties = false
Anti-loop / reproceso	Filtro por Estado Pendiente y NOT(Derivado a recupero)
HITL	Accion critica requiere decision humana
Idempotencia HITL	Busqueda solo de expedientes en Pendiente revision humana
Datos	Dataset sintetico; no se utilizaron expedientes reales

Para un despliegue productivo se requeririan controles adicionales de autenticacion del formulario HITL, permisos por rol, retencion, privacidad, anonimizado cuando corresponda, auditoria y politicas de acceso a datos.

7. Dashboard y observabilidad

Airtable concentra el monitoreo operativo. La Interface construida incluye KPIs de negocio y una seccion de resiliencia. Para la entrega, la Interface se demostrara mediante capturas suficientes y video; adicionalmente se provee una Shared View publica read-only de los datos operativos.

KPI / visualizacion	Definicion
Total de expedientes	Conteo de registros en Expedientes
Recovery Score promedio	Promedio del indice heuristico; no equivale a probabilidad
Derivados a recupero	Casos con flag de derivacion
Pendientes de revision humana	Casos a la espera de HITL
No priorizados	Casos cerrados por decision humana
Total de ejecuciones	Conteo de Logs Ejecuciones
Errores	Logs con checkbox Error = Si
Tasa de error	Errores / total de ejecuciones
Ejecuciones por resultado	Distribucion de resultados del workflow

Tasa de error = ejecuciones con Error = Si / total de ejecuciones registradas

La tasa se calcula a nivel de ejecucion y no de expediente: un mismo caso puede fallar, reintentarse y luego finalizar correctamente.

Shared View publica (read-only): [Abrir Airtable](#)

Criterio de evidencia acordado para la entrega: Ante la limitacion del plan de Airtable para publicar la Interface, se incluyen capturas suficientes del dashboard funcional y del monitoreo, complementadas con la Shared View publica de datos.

8. Stress test y validacion

Se definieron diez expedientes sinteticos antes de ejecutar el flujo para cubrir casos normales y de borde. El objetivo fue comprobar comportamiento funcional y resiliencia, no obtener precision estadistica de produccion.

Caso	Proposito principal
EXP-001	Oportunidad clara de recupero
EXP-002	Ausencia de tercero
EXP-003	Choque y fuga / identificacion parcial
EXP-004	Responsabilidad ambigua
EXP-005	Contradiccion documental
EXP-006	Expediente incompleto
EXP-007	Bajo monto con senales fuertes
EXP-008	Alto monto con evidencia debil
EXP-009	Urgencia critica
EXP-010	Posible limitacion contractual

La prueba masiva del core confirmo el procesamiento de los diez casos, el override de EXP-002 a No elegible por regla y la alerta legal en EXP-010. El stress test tambien revelo la fragilidad del HITL embebido en la misma ejecucion masiva; ese hallazgo motivo el desacoplamiento definitivo del bloque de revision humana.

La rama Batch se valido en una ejecucion separada con 8 requests elegibles en ese estado del dataset: 8 completados, 0 fallidos, y 8 respuestas con HTTP 200 y los nueve campos exactos del schema estructurado.

Limite metodologico: El dataset es pequeno y sintetico. No se utilizan estas pruebas para inferir precision predictiva, tasa real de recupero ni performance legal en produccion.

9. Evidencias y estructura de entrega

Las capturas no necesitan saturar este PDF. Se recomienda mantenerlas como evidencia numerada dentro del repositorio GitHub y utilizar las mas relevantes en el video de demostracion.

Evidencia minima recomendada	Que demuestra
01 - Workflow n8n completo	Arquitectura implementada y nombres de nodos
02 - Ejecucion core multi-item	Procesamiento de los casos sinteticos
03 - EXP-002	Override No elegible por regla
04 - EXP-010	Alerta por posible limitacion contractual
05 - Gmail enviado	Salida operacional
06 - Formulario HITL	Intervencion humana independiente
07 - Revisiones Humanas + cambio de estado	Persistencia de la decision
08 - Logs de ejecucion	Trazabilidad y errores
09 - Dashboard Airtable	KPIs y tasa de error
10 - Batch completed 8/8	Procesamiento masivo real
11 - Batch output JSONL	Respuestas estructuradas y custom_id

9.1. Estructura sugerida del repositorio GitHub

```

AI-Recovery-Copilot/
|-- README.md
|-- docs/
|   `-- AI_Recovery_Copilot_Documentacion_y_Arquitectura.pdf
|-- workflow/
|   `-- AI_Recovery_Copilot_n8n.json
|-- evidence/
|   |-- 01_workflow.png
|   |-- 02_stress_test.png
|   |-- ...
|   `-- 11_batch_output.png
|-- batch/
|   |-- recovery-copilot-batch.jsonl
|   `-- batch_output.jsonl
`-- data/
    `-- casos_sinteticos(csv o json)

```

10. Limitaciones y proximos pasos

- Los pesos y thresholds del scoring son hipotesis de PoC y requieren calibracion con historico real y expertos.
- El sistema no determina responsabilidad juridica, fraude ni procedencia definitiva del recupero.
- Una implementacion productiva requiere controles adicionales de privacidad, autenticacion y gobierno de datos.
- Prompt Caching no genero tokens cacheados en la prueba realizada; cualquier ahorro futuro debe medirse y no asumirse.
- La Interface de Airtable se evidencia con capturas y video; la Shared View publica complementa el acceso read-only a los datos.

11. Conclusion

AI Recovery Copilot demuestra una arquitectura en la que automatización convencional, IA generativa y decisión humana cumplen funciones separadas. La IA interpreta información no estructurada; las reglas determinísticas calculan y enrutan; Airtable conserva el estado; n8n orquesta; Gmail comunica; y el HITL controla la acción crítica.

La Batch API fue implementada y validada end-to-end, aportando una estrategia real de procesamiento diferido y un ahorro presupuestario del 50% frente al equivalente sincrónico. El resultado es un copiloto de screening y priorización con trazabilidad, límites explícitos y supervisión humana, no un sistema que decide autónomamente sobre recuperos.

Anexo A. Cobertura de la rubrica

Criterio	Cobertura en la entrega
Mapa de arquitectura	Sección 2 + Figura 1: triggers, routers, APIs, IA, destinos, HITL y Batch
Estructuras de datos	Sección 4 + Figura 2 + esquemas JSON
Optimización de costos	Sección 5: separación determinística/IA, matriz, Batch real, estimación 500 casos, caching medido
Seguridad y resiliencia	Sección 6: minimización, errores, retries, anti-loop, HITL, tipos
Dashboard	Sección 7 + Shared View + capturas en evidence/
Stress test	Sección 8: 10 casos sintéticos + pruebas de bordes + rediseño HITL
Archivos técnicos	n8n JSON, JSONL de entrada/salida Batch y datos sintéticos en GitHub
Video 3 min	Demostración final del flujo, dashboard, HITL y dos casos representativos

Referencias

- [1] [BARBUSS - Solutions / Recoveries](#)
- [2] [Argentina.gob.ar - Ley 17.418, Art. 80](#)
- [3] [BARBUSS - Acquisition of HDI Seguros Argentina and Uruguay \(06/08/2025\)](#)
- [4] [OpenAI - GPT-5 Mini model](#)
- [5] [OpenAI - Batch API reference](#)
- [6] [n8n - Gmail Message Operations / Send and Wait](#)
- [7] [OpenAI - Model guidance / prompt caching](#)